

Trabalho de Clusterização – K-means e preparação para aplicação da técnica KNN.

O objetivo deste trabalho é implementar um processo de clusterização utilizando a técnica K-means, explorando cada uma das etapas envolvidas e preparando a base de dados para uma futura implementação do algoritmo KNN (K-Nearest Neighbors). O trabalho será realizado em seis etapas, detalhadas a seguir:

1. Estrutura de dados inicial e manipulação

Desenvolver uma estrutura de dados capaz de armazenar registros (elementos), com as seguintes funcionalidades:

- Inserção de novos registros.
- Remoção e alteração de registros.
- Indicação, para cada elemento, se ele é ou não o centróide de um cluster. Inicialmente, cada estrutura de dados deve conter apenas um elemento, formando assim dois clusters distintos (cada um com um único elemento). A estrutura deve permitir a inclusão de novos registros, que representarão a formação e o crescimento de cada cluster.

2. Atribuição de elementos e cálculo de distâncias

Sempre que um novo elemento for incluído, deve ser realizada:

- A verificação de qual cluster está mais próximo desse novo elemento, por meio do cálculo da distância euclidiana.
- A atribuição do novo elemento ao cluster mais próximo.
- A atualização da informação que identifica o centróide de cada cluster, mesmo que seja um centróide virtual (calculado em tempo real).

3. Recálculo do centróide e reorganização

Após a atribuição do novo elemento a um cluster, deve ser:

- Feito o recálculo do centróide desse cluster.
- Atualizada a marcação do centróide na estrutura de dados.
- Realizada a reorganização dos elementos de cada cluster, considerando o novo equilíbrio e a dispersão dos dados.

4. Análise de dispersão e criação de novos clusters

Avaliar os elementos de cada cluster para identificar se estão se tornando muito distantes de seus centróides originais. Para isso, deve-se:

- Definir um limiar que indique o que significa “estar distante” do centróide.
- Localizar os “k” elementos mais distantes de seus centróides e mais próximos do outro cluster.
- Caso sejam encontrados elementos que se encaixem nesses critérios, eles devem ser removidos de seus clusters originais e formar um novo cluster.
- Reorganizar todos os clusters (inclusive o novo, se criado), garantindo a consistência dos centróides.

5. Adequação de dados para uso futuro com KNN

Preparar a base de dados para uma futura implementação do algoritmo KNN.

Para isso, deve-se:

- Alterar ou estender a estrutura de dados existente para suportar elementos categóricos (strings).
- Implementar um mecanismo para converter esses elementos categóricos em valores quantitativos, durante a execução do código, sem alteração direta dos dados primários.

Essa transformação permitirá que a base de dados seja utilizada em algoritmos que exigem dados numéricos.